# OpenACC





## Introduction

## 全名: Open Accelerators

- 透過compiler directive讓程式能在GPU上執行
- 和CUDA相比門檻降低許多





# **OpenACC vs CUDA**

#### CUDA

- CudaMalloc(...):宣告GPU上的記憶體
- CudaMemcpy(...): 搬移資料
- functionname<<<thread, blocks>>>(...):要自己寫Cuda Kernel Function

### === 入門門檻高 ===

## OpenACC

- 不用宣告device上的記憶體
- #pragma acc data copy(...):用簡單的clause就可以搬移資料
- 直接用parallel region就可以port到GPU上

=== 可以快速上手 ===






- #pragma acc <directive> <clause>
  - #pragma 是一種 compiler hint
  - o acc 告訴compiler這是OpenACC的pragma
  - directive 是OpenACC告訴compiler指示
  - clause 是OpenACC對directive進行補充或優化的指示



- #pragma acc parallel
  - o parallel 告訴compiler這段程式碼要redundantly parallelize
  - redundantly parallelize:多餘地平行,並沒有分工



execute the entire loop





- #pragma acc parallel loop
  - loop 告訴compiler這個loop要parallelize
  - 同時也告訴compiler這個loop是可以被安全地平行


The iterations of the loop will be broken up evenly among

the parallel gangs.

```
#pragma acc parallel
{
    #pragma acc loop
    for(int i = 0; i < N; i++)
    {
        // Do Something
    }
    The loop directive informs the compiler which loops to parallelize.</pre>
```

The gangs will then execute in

parallel with one another.



- #pragma acc parallel loop reduction(<operation>:<target>)
  - reduction 告訴compiler某個目標要被reduce
  - reduce:對選定的目標進行全局的 operation操作

```
int sum = 0;
#pragma acc parallel loop reduction(+:sum)
for(int i = 0, i < N, i++) sum += i;</pre>
```





- #pragma acc kernels
  - 全部行為交給 compiler決定
  - 可以把sequential code也包進去
- #pragma acc kernels loop independent
  - 告訴compiler這個loop是可以被安全地平行, 並強迫平行它

```
#pragma acc kernels
{
    for(int i = 0; i < N; i++)
    {
        // Do Something
    }
    for(int i = 0; i < M; i++)
    {
        // Do Something Else
    }
    With the kernels
} directive, the loop
directive is implied.</pre>
```

Each loop can have a different number of gangs, and those gangs can be organized/optimized completely differently.





## **Inclass Lab**

### 把TODO1和TODO2完成

- module purge
- module load nvhpc-hpcx/23.3
- cp -r /home/hpci24/share/openacc/ ~/
- cd openacc

## === 改code ===

- make
- srun --gres=gpu:1 ./laplace

這裡用的是unified memory, 不用複製資料

沒加速32s > 加速後3s





## Data Management

- 可以只複製部分資料
  - #pragma acc parallel loop copy(A[1:N-2])

- #pragma acc data copy(...)
  - 把資料複製進GPU,在parallel region結束後將資料複製回 CPU
- #pragma acc data copyin(...)
  - 把資料複製進GPU,在parallel region結束後刪除GPU上的資料
- #pragma acc data copyout(...)
  - 把資料複製回CPU,在parallel region結束後刪除GPU上的資料
- #pragma acc data create(...)
  - 在GPU宣告一個空間,不進行任何複製動作
  - 有暫存用的變數時,使用這個 clause就不需要進行複製進出的動作



## Data Management

```
#pragma acc data copy(A[0:N])
#pragma acc parallel
{
     #pragma acc loop
     for(int i = 0; i < N; i++) A[i] = 0;</pre>
```

```
Allocate 'a' on GPU Copy 'a' Execute Kernels Copy 'a' From GPU to GPU To GPU To CPU To CPU
```

```
#pragma acc kernels copy(a[0:N])
for(int i = 0; i < N; i++){
  a[i] = 0;
}</pre>
```



# **Loop Optimization**

- #pragma acc parallel loop collapse(...)
  - 在tightly nested的迴圈中可以使用
  - o collapse 可以攤平迴圈,把多個迴圈變成一個大迴圈平行

```
#pragma acc parallel loop collapse( 2 )
for(int j = 0; j < M; j++) {
    for(int k = 0; k < Q; k++) {
        < loop code >
```

#### TIP1:

當外層的迴圈過小時,攤平迴圈可以增加GPU的使用率

#### TIP2:

Compiler會傾向於vectorize最內層的迴圈,因此如果最內層的迴圈過小時,collapse就可以增加迴圈深度,至此內層迴圈的vectorize更有效



# **Loop Optimization**

- #pragma acc parallel loop tile(x, y)
  - 把迴圈break給多個tiles(blocks)計算

```
#pragma acc parallel loop tile( 32, 32 )
for(int j = 0; j < 128; j++) {
    for(int k = 0; k < 128; k++) {
        < loop code >
    }
}
```

#### TIP1:

盡量讓tile大小是32的倍數,Nvidia GPU的一個worker和vector中的threads都是以32為單位執行

#### TIP2:

不要用超過32\*32大小的tiles, 因為在NVIDIA GPU中, 一個gang的threads數最高是1024(32\*32)





# **Extra Study**

OpenACC教學

OpenACC官網

Gang/Worker/Vector

